

Rapport de validation technique du traitement BERT

Ce rapport présente la validation technique des sorties produites par le modèle BERT appliqué aux avis Airbnb. L'objectif est de vérifier que les colonnes générées sont présentes, complètes et cohérentes avant leur fusion avec les données tabulaires.

1. Colonnes attendues dans le fichier avis

Colonne	Présente
listing_id	True
comments_clean	True
bert_label_raw	True
bert_confidence	True
bert_stars	True
sentiment_score	True
sentiment_label	True

Le fichier des avis avec sentiment contient 1535592 avis exploitables et 12 colonnes. Les colonnes attendues correspondent aux identifiants des annonces, au commentaire nettoyé et aux sorties principales du modèle BERT.

2. Valeurs manquantes dans les sorties BERT

Variable	Valeurs manquantes
bert_label_raw	0
bert_confidence	0
bert_stars	0
sentiment_score	0
sentiment_label	0

Aucune valeur manquante n'a été détectée dans les principales sorties BERT. Chaque avis chargé dispose donc d'une prédiction exploitable.

3. Distribution des sentiments

Sentiment	Nombre	Pourcentage
positif	1449369	94.39
neutre	51018	3.32
negatif	35205	2.29

La distribution obtenue est composée de 94.39 % d'avis positifs, 3.32 % d'avis neutres et 2.29 % d'avis négatifs. Cette répartition est cohérente avec le contexte Airbnb, où les avis sont généralement très majoritairement positifs.

4. Distribution des étoiles prédites par BERT

Étoiles BERT	Nombre
1	11787
2	23418
3	51018
4	352490

Étoiles BERT	Nombre
5	1096879

5. Statistiques des scores avis par avis

index	bert_confidence	bert_stars	sentiment_score
count	1535592.0	1535592.0	1535592.0
mean	0.6795	4.6276	0.8138
std	0.1512	0.6955	0.3478
min	0.2076	1.0	-1.0
25%	0.5572	4.0	0.5
50%	0.6809	5.0	1.0
75%	0.8034	5.0	1.0
max	0.9952	5.0	1.0

Indicateur	Nombre d'avis
bert_confidence < 0.50	191843
bert_confidence < 0.70	827798
bert_confidence >= 0.90	110475

Le score de confiance correspond à la probabilité associée à la classe choisie par le modèle. Il mesure la certitude interne du modèle, mais ne constitue pas une vérité terrain.

6. Colonnes attendues dans le fichier agrégé par annonce

Colonne	Présente
id_clean	True
nb_avis_textuels_bert	True
bert_stars_moyen	True
bert_confiance_moyenne	True
sentiment_bert_moyen	True
sentiment_bert_min	True
sentiment_bert_max	True
sentiment_bert_ecart_type	True
nb_avis_bert_positifs	True
nb_avis_bert_neutres	True
nb_avis_bert_negatifs	True
ratio_avis_bert_positifs	True
ratio_avis_bert_neutres	True
ratio_avis_bert_negatifs	True

Le fichier agrégé contient 41923 annonces avec au moins un avis textuel analysé. Chaque ligne correspond à une annonce et résume les prédictions BERT associées à ses avis.

7. Valeurs manquantes dans le fichier agrégé

Variable	Valeurs manquantes
id_clean	0
nb_avis_textuels_bert	0
bert_stars_moyen	0
bert_confiance_moyenne	0
sentiment_bert_moyen	0
sentiment_bert_min	0
sentiment_bert_max	0
sentiment_bert_ecart_type	0
nb_avis_bert_positifs	0
nb_avis_bert_neutres	0
nb_avis_bert_negatifs	0
ratio_avis_bert_positifs	0
ratio_avis_bert_neutres	0
ratio_avis_bert_negatifs	0

8. Statistiques des variables agrégées

sentiment_bert_moyen	sentiment_bert_min	sentiment_bert_max	sentiment_bert_ecart_type	nb_avis_bert_positifs	nb_avis_bert_neutres	nb_avis_bert_negatifs
0	41923.0	41923.0	41923.0	41923.0	41923.0	41923.0
	0.0212	0.9546	0.2669	34.5722	1.2169	0.8398
	0.687	0.2247	0.1908	63.189	2.9117	1.8961

sentiment_bert_moyen	sentiment_bert_min	sentiment_bert_max	sentiment_bert_ecart_type	nb_avis_bert_positifs	nb_avis_bert_neutres	nb_avis_bert_negatifs
	-1.0	-1.0	0.0	0.0	0.0	0.0
	-0.5	1.0	0.1654	4.0	0.0	0.0
	0.0	1.0	0.25	12.0	0.0	0.0
	0.5	1.0	0.3757	38.0	1.0	1.0
	1.0	1.0	1.0	1690.0	129.0	91.0

9. Contrôle des ratios

Indicateur	Valeur
Nombre d'annonces avec somme des ratios différente de 1	0
Somme moyenne des ratios	1.0000
Somme minimale des ratios	1.0000
Somme maximale des ratios	1.0000

Les ratios d'avis positifs, neutres et négatifs sont cohérents : leur somme est égale à 1 pour chaque annonce.

10. Conclusion

La validation technique confirme que le traitement BERT a produit des sorties complètes et cohérentes. Le fichier avis contient 1535592 avis exploitables avec des prédictions de sentiment sans valeurs manquantes. La distribution obtenue est fortement positive (94.39 %), ce qui est cohérent avec le contexte Airbnb. Le fichier agrégé contient 41923 annonces avec au moins un avis textuel analysé. Les ratios agrégés sont cohérents et les variables produites peuvent être utilisées pour la fusion avec les données tabulaires.